

UNESCO 中国非物质文化遗产 在 TikTok 美区的传播研究

阶段进展与方法论汇报

阶段 数据基底构建（接近完成） 数据基准 baseline 全量采集 + 三轮逐页验证 日期 2026-06-12

本材料定位为 **研究进展与方法论汇报**，而非成果展示。重点在于：建立可靠的研究设计、坐实数据采集中的关键技术约束、并以严格的口径与质控保证后续分析的数据洁净度。文中所有「**假设**」均**明确标注**，未经数据验证不作为结论引用。

01 研究设计

研究问题

判断每一个 UNESCO 认定的中国非遗项目，在 TikTok 美区是处于「**真出海**」（破圈到非华人 / 英文世界）还是「**内圈循环**」（华人 / 中文小圈层内传播），并为每个项目建立**传播画像**。

研究对象与口径

- 对象 = 非遗项目（44 个）**。视频与搜索词只是采集 **素材与探针**，不是研究单元——结论落在项目层级。
- 名录口径锁定 2024 年 12 月名录**，2025 年的转列 / 新增（如咏春拳）不纳入本轮，作为明确的边界声明。

名录类别	全称	数量	「隐形」的含义
RL	人类非遗代表作名录	36	功能化失败 （理应被代表却没传播开）
USL	急需保护名录	7	常态（本就濒危，预期内）
GSP	优秀保护实践名册	1	单列识别，不参与规模比较

为何按名录类别分层

RL 项目隐形与 USL 项目隐形性质完全不同——前者是失败，后者是常态。若混为一谈，核心论点会被一击即破。GSP（福建木偶戏传承计划）保护的是「传承机制」而非遗产本身，故单列处理。

分层框架：规模 × 触达 双轴（数据基础不对等，区别处理）

- **轴 A — 触达轴（主轴，数据扎实）**：以同一项目下中文词 vs 英文词的采集量差异衡量「触达广度」。英文 >> 中文 → 疑似出海；中文 >> 英文 → 疑似内圈；双浅 → 低传播。
关键优势：衡量的是**相对可见度**而非绝对总量，因此不受后文所述的接口翻页上限影响。
- **轴 B — 规模轴（辅轴，数据脆弱）**：以 hashtag 的 `videoCount` 衡量绝对规模，配 `clean / noisy / unavailable` 三态标记，缺失不硬填。

画像维度（5 个）

内容形态 · 创作者构成 · 语言 · 传播形态（四个可观测维度全量做）+ 受众（降级为评论区语言构成，抽样质性佐证，排在分层之后执行）。

方法论原则

受众的精确族裔比例平台不提供、也无法可靠推断，故诚实降级为「有偏代理」，不做无法支撑的精确声明。

02 采集架构与规模

采集架构

- **采集通道**：TikTok search 接口（`/api/search/item/full/`），逐页翻页（每页 30 条）。
- **账号 / 代理池**：4 个独立账号，各绑定美国 residential SOCKS5 代理出口（FL / CA / NM 多地）。
- **调度器（账号轮换 + 冷却队列）**：最细粒度调度单元 = （项目，搜索词）；单账号连续采集 N 词后主动冷却 90 秒并轮换下一账号（预防性轮换，降低风控触发）；失败词自动重入队列、可重采；（项目，term）粒度落盘，保证可追溯。
- **运行环境**：headless 浏览器（xvfb 虚拟显示），独立 Python 虚拟环境。

baseline 采集规模

197

搜索词 (term)

29,407

唯一视频 (去重后)

0

失败 / 限流

0

重采次数

指标	数值	说明
has_data	196	有数据
zero_real	1	真实零结果 (chinesemedicine latin 词)
failed	0	无任何限流 / 技术失败
采集视频 (原始 / 去重)	32,579 / 29,407	—
单词采集量 (均 / 中 / 最大)	166 / 174 / 196	整齐天花板，见 S3

质量核心指标

零失败、零重采——197 个词全部解析成功，没有任何限流或技术噪声混入数据池。这是后续判定能够干净进行的前提。

03 方法论发现 (本阶段核心)

发现一：search 接口存在隐蔽的翻页硬顶

现象：197 个词的最大采集量整齐停在 196，无一突破。这种「整齐的天花板」不像自然现象，触发了对接口本身的怀疑。

逐页验证实验：设计单词逐页探针，对高传播词逐页记录每页返回的 items / cursor / has_more：

- chinesenewyear (百万级话题)：前 6 页每页满 30 条、has_more=1，第 7 页突降至 8 条、has_more=0，停在 188 条；
- calligraphy 同模式停在 192 条；两词独立复现。

结论（已坐实，非推测）

search 接口在约第 6–7 页（offset 180–210）存在翻页硬顶。到顶后返回「半页 + has_more=0」，伪装成自然采空。

为何不是限流？限流的特征是整页空响应（empty_response）；而这里是「半页有数据 + has_more=0」，是接口逻辑层面的硬顶，不是风控拦截。两者在数据上可清晰区分。

处理：判据从「数值」升级为「行为模式」

接口硬顶意味着 search 采集量不能直接当作传播规模——高传播项目的真实量都被压平在 ~180–200。最初的判定用 cursor 数值阈值，但逐页验证暴露了它的脆弱：同一数值既可能是触顶、也可能是真实采空。因此判据升级为「has_more 突变模式 + 上限区排除」：

```
# 触顶判据（cursor 数值已降级为参考字段，不参与判定） 触顶 = 末页未满（<30 条） AND 倒数第二页满（≥28 条）且 has_more=1 AND 停止原因为采空 / 空页 AND 已进入上限区（已翻 ≥6 页 OR cursor≥180）
← 关键排除项
```

「上限区排除」是关键：第 6 页之前就 has_more=0，必然是真实采空，不算触顶。

发现二：「边界态」——判定的稳定性问题

在验证中发现一个更深的现象：同一个词，多次采集结果不同。以「藏医」为例（三次实测）：

实测轮次	停止页	cursor	判定
第 1 次	第 5 页采空	150	真实采空
第 2 次	第 6 页触顶	180	触顶
第 3 次	第 6 页触顶	180	触顶

每次判定都正确。差异源于该词真实结果量恰好 ≈150，正卡在接口第 5–6 页的边界上，采集时的微小抖动就会改变它落在哪一档。

方法论意义

结果量在临界点的词，**单次采集判定本质不稳定**。强行将其钉死为「采空」或「触顶」，等于**用假确定性掩盖真实的不确定性**——后续分层会因此把一个可能高传播触顶的项目误判为「中等真实量」，造成方向性误判。

处理决策：为这类词设立**第三态「边界态 (boundary)」**，明确标记为「待用其他方法定位」，而非硬归入任一确定档。这保证了另外两档（确定触顶 / 确定采空）的洁净。

04 口径与质控

洁净度红线：五类严格分开，绝不混淆

类别	含义	处理原则
failed	限流 / 技术噪声（空响应）	可重采，永不计入低传播
zero_real	真实零结果	研究结论级的「真实零」
has_data	有数据	正常使用
ceiling_capped	触接口上限被压平	不可当真实规模横向比较
boundary	临界抖动，单次判定不稳	待其他方法定位，不硬归类

不可妥协的红线

把限流噪声、真实零、触顶压平混入同一池，分层就建在脏数据上，结论一推就倒。

各采集通道「能给 / 不能给」边界

通道	能给	不能给
search 接口	触达广度（中英可见度对比）、低/高传播两档、视频级数据	真实总量（>180 被压平）、规模横向比较
hashtag videoCount	精确总量（唯一可比规模源）	非每词都有对应 hashtag；通用词撞词高估（noisy）
视频级 stats	单视频热度	项目级传播规模（视频热 ≠ 项目传播广）
评论区	评论区语言构成（受众有偏代理）	受众精确族裔 / 比例

研究文档纪律：决策与假设分区

研究纲领作为活文件维护，强制区分「已定决策」（每条带「为什么」+「何时重新讨论」）与「待验证假设」（明确标注，未经数据验证不得当结论引用）。任何新发现 → 更新对应区 + 追加修订记录。

已知局限（提前声明，不掩盖）

- 1. **search 接口上限**：>~180–200 的项目真实量被压平，规模只能分「低 / 高」两档，高传播内部区分依赖 hashtag。
- 2. **hashtag videoCount 含撞词噪声**，部分项目规模「不可得」。每项目规模状态已标 clean/noisy/unavailable。
- 3. **受众用评论区语言代理**，小样本、有偏、非统计比例。
- 4. **仅 US 单 region residential 出口**，结论限于美区，不外推全球。
- 5. **cursor=180 档为单轮验证**，可信度相对高（未暴露骑墙证据），但不排除个别骑墙词未被抖动捕获——以局限声明覆盖此残余风险，不额外花成本全补。
- 6. 名录以 2024-12 为准，2025 变动未纳入。

05 当前进度与下一步

触顶判定的三轮验证（方法论发现的落地）

为坐实接口上限并识别边界态，对存疑词做了逐页验证实验。其中 cursor=150 一档首轮实测即出现触顶/采空近五五分（11:9），**自证整档骑墙**，故对该档 20 词统一做第二轮采集，凡两轮不一致者升 boundary：

验证批次	词数	结果
首轮存疑词验证 (cursor=180 抽样)	39	38 触顶 + 1 边界 (藏医)
边界词全量验证 (cursor=150 全档 + cursor=180 未验)	73	55 触顶 + 18 采空
cursor=150 档第二轮 (抖动识别)	20	8 一致触顶 + 9 一致采空 + 3 抖动升边界

补采的价值

cursor=150 档若不验、直接信首轮数据，有 11 个项目会被误判为「中等真实量」，实际是触顶高传播——正是要避免的方向性误判，命中率过半。第二轮又揪出 3 个原本会被单次误判的骑墙词。

全量 baseline 最终三态分布 (197 词)

ceiling_capped 触顶压平 · 127 exhausted 真实采空 · 65 boundary 边界态 · 4 zero_real 真实零 · 1



边界态 4 词：藏医、药浴、福船、seagoddess。127/197 (64%) 的词触顶被压平——再次坐实「search 采集量绝不能当规模」。派生为独立标记文件，原始数据未改动。

下一步流程

1 数据基底

接近完成

baseline 采集 ✓

→

接口上限坐实 ✓

→

判据升级 ✓

→

三轮验证 ✓

→ 给 baseline 派生 触顶 / 采空 / 边界 三态标记 (纯标注, 不重采、不动原始数据) ✓

2 双轴分层

下一步

轴 A 触达：算每项目中/英 term 采集量差异 → 触达档 (英主 / 中主 / 双浅)

轴 B 规模：采 hashtag videoCount + 标 clean / noisy / unavailable

→ 合成分层表：项目 | 名录类别 | 触达档 | 规模值+状态 | 综合判断 结论先按名录类别分组解读 (RL 隐形=失败 / USL 隐形=常态 / GSP 单列)

3 项目画像

后续

全量：内容形态 / 创作者构成 / 语言 / 传播形态

→ 受众佐证 (分层后)：挑十几个代表项目 → 抽头部视频评论区 → 语言构成印证出海 / 内圈判断

待决问题 (已识别, 等数据再定)

- 正式采集每词的 count 上限 (既然 >210 采不到, N 设太大无意义, 等触达分布出来再定)。
- 是否扩展多 region 做对比 (等美区分层结论出来再定)。
- 视频相关性清洗的判定锚点 (含撞词噪声, 清洗口径未定, 目前不假设)。

本材料随研究进展持续更新。所有「假设」均明确标注, 未经数据验证不作为结论引用。规模缺失标「不可得」不硬填; 真实零 ≠ 失败/限流, 严格分开。